

Исследование методов обучения для Automatic Speech Recognition (ASR)

Аннотация

В данной статье рассматриваются современные методы обучения для автоматического распознавания речи (ASR). Проводится обзор шести методов: SpeechStew, Noisy Student Training, Conformer, ContextNet, W2V-BERT и Conv + Transformer + wav2vec2.0 + pseudo labeling.

Ключевые слова

автоматическое распознавание речи (ASR)

методы обучения

неразмеченные данные

трансформеры

самообучение

безнадзорное предварительное обучение

Введение

Распознавание речи - одна из ключевых областей исследований в области искусственного интеллекта и обработки естественного языка. Эта технология, изначально разработанная для преодоления барьеров между человеком и компьютером, сегодня играет значительную роль в нашей повседневной жизни.

От голосовых помощников на мобильных устройствах до систем распознавания речи в медицинских и банковских приложениях, распознавание речи значительно упростило взаимодействие между человеком и технологией.

Распознавание речи обладает широким спектром применений, включая автоматизацию задач ввода данных, создание доступных средств связи для лиц с ограниченными возможностями, улучшение систем навигации и многое другое. Эта технология имеет значительный потенциал для улучшения качества жизни и эффективности бизнес-процессов.

Несмотря на успехи, достигнутые в области распознавания речи, остаются многие вызовы и возможности для улучшения. Исследователи и инженеры продолжают стремиться к разработке более точных, быстрых и устойчивых систем распознавания речи. Это включает в себя разработку новых алгоритмов и методов машинного обучения, а также использование современных вычислительных ресурсов.

Исследование в области распознавания речи имеет большое практическое значение и способствует развитию технологий, способных расширить возможности взаимодействия между человеком и машиной.

Цель данной исследовательской работы заключается в проведении обзора современных методов и технологий в области распознавания речи, а также в проведении сравнительного анализа их производительности и эффективности.

Исследование проводилось на базе данных LibriSpeech.

LibriSpeech [7]— это сборник из примерно 1000 часов английской речи для чтения с частотой 16 кГц, подготовленный Василием Панайотовым при содействии Дэниела Пови. Данные взяты из прочитанных аудиокниг проекта LibriVox, находящихся в общественном достоянии, в качестве немаркированных данных для обучения под наблюдением, и были тщательно сегментированы и выровнены.

В данной работе рассматривались такие модели, как SpeechStew, Noisy Student Training, Conformer, ContextNet, W2V-BERT, Conv + Transformer + wav2vec2.0 + pseudo labeling.

Современные методы распознавания речи

SpeechStew

SpeechStew [1] – это простой подход к сквозному распознаванию речи, который использует как многодоменное обучение, так и обучение передаче.

SpeechStew создается следующим образом:

1. Объединение всех доступных данных распознавания речи без какой-либо зависящей от домена повторной балансировки или повторного взвешивания.
2. Обучение одной большой нейронной сети (модель с параметрами 100 М или 1В) на основе объединенных данных.
3. При представлении нового невидимого набора данных с низким ресурсом, следует точно отрегулировать SpeechStew в новом помеченном наборе данных.

Метод не использует никаких доменных меток и не вводит никаких дополнительных гиперпараметров для объединения данных.

Speech Stew использует архитектуру Conformer [8] RNN-T [9]. SpeechStew обладает мощными возможностями для обучения переводу.

Noisy Student Training

NST [2] использует немаркированные данные для последовательного обучения моделей, каждая из которых становится учителем для последующей модели. Модели сбалансированы и фильтруются для обеспечения точности меток. Алгоритм предполагает наличие меченого множества S , немеченого множества U и фиксированного LM, обученного на отдельном корпусе текстов.

Процесс создания серии моделей ASR включает в себя следующие шаги:

1. Обучение модели M_0 на меченом множестве S с помощью SpecAugment. Установка $M = M_0$.
2. Совмещение модели M с LM и измерение ее производительности.

3. Генерация множества меток $M(U)$ с использованием объединенной модели.
4. Фильтрация сгенерированных меток $M(U)$ для получения $f(M(U))$.
5. Балансирование фильтрованных меток $f(M(U))$ для получения $b - f(M(U))$.
6. Смешивание множества данных $b - f(M(U))$ и множества S . Использование смешанного множества данных для обучения новой модели M_0 с помощью SpecAugment.
7. Установка $M = M_0$ и возвращение к пункту 2 для новой итерации.

Conformer

Модель Conformer [3] - сверточный трансформатор для распознавания речи, достигающий высокой точности на эталоне LibriSpeech на основе трансформаторов и CNN.

Структура аудиокодера Conformer начинается со сверточного слоя субдискретизации, за которым следуют блоки Conformer. Блок Conformer состоит из модуля самовнимания и модуля свертки, разделенных промежуточным соединением. Он также содержит модуль прямой подачи.

1. Многоголовый модуль самовнимания (multi-headed self-attention (MHSA)): в данном кодере применяется многоголовой модуль самовнимания с относительным позиционным кодированием. Это позволяет более эффективно обобщать входные последовательности различной длины и делает кодер более устойчивым к изменчивости длины высказываний. Используются остаточные блоки с преднормой и включением отсева для облегчения обучения и регуляризации глубоких моделей.
2. Модуль свертки: модуль свертки начинается с механизма стробирования, содержит точечную свертку, закрытый линейный блок (GLU), 1D свертку и пакетную нормализацию. Эти шаги

помогают облегчить обучение глубоких моделей и предоставляют необходимую регуляризацию.

3. Модуль прямой подачи: после MHSA следует модуль прямой подачи, содержащий два линейных преобразования с активацией Swish, остаточные связи и нормализацию слоев внутри остаточных блоков.
4. Блок конформера: Conformer представляет собой два модуля прямой подачи, обрамленные многоголовым модулем самовнимания и модулем свертки. Это улучшенная структура Transformer с двумя полушаговыми слоями прямой подачи перед и после слоя самовнимания, обеспечивая остаточную связь и нормализацию для регуляризации сети.

ContextNet

Модель ContextNet [4], основанная на End-to-End архитектуре RNN-Transducer, состоит из трех ключевых компонентов: аудио-кодировщика, кодировщика меток и совместной сети для объединения и декодирования. В данной модели предложен новый аудио-кодировщик, который оперирует сверточными слоями и преобразует входную речь в высокоуровневое представление.

Аудио-кодировщик включает последовательные блоки свертки, где каждый блок содержит ключевые модули: "squeeze-and-excitation", сверточные слои с разделением по глубине и функцию активации Swish. "Squeeze-and-excitation" порождает веса для каждого канала входных данных, которые затем используются для умножения на кадры, представленные сигналом. Каждый блок свертки включает несколько сверточных слоев с пакетной нормализацией и функцией активации, формируя тем самым высокоуровневое представление.

Архитектура блока свертки представляет последовательное применение функции активации к сверточным слоям с пакетной нормализацией. Этот блок

также включает в себя модуль "squeeze-and-excitation", сверточные слои с разделением по глубине и функцию активации Swish. Для достижения оптимального баланса между числом слоев и временем модель использует сверточную свертку с шагом в 8 раз для временного уменьшения, что обеспечивает хорошее соотношение между вычислительной нагрузкой и точностью.

W2V-BERT

Изложение архитектуры модели w2v-BERT [5] для предварительного обучения включает в себя несколько компонентов. Блок кодирования признаков извлекает скрытые речевые представления из акустических входов, модуль контрастного обучения использует механизм квантования и стек блоков конформера для решения контрастной задачи, а модуль маскированного прогнозирования, также со стеком блоков конформера, генерирует контекстуализированные речевые представления. Во время предварительного обучения используются только неразмеченные речевые данные.

Блок кодирования признаков действует как блок сверточной дискретизации, уменьшая длину последовательности акустического входа. Контрастный модуль, содержащий стек блоков конформера, имеет целью преобразовать вывод блока кодирования признаков в представительные речевые единицы. Это достигается через механизм квантования, при котором создаются контекстные и квантованные векторы.

Модуль маскированного прогнозирования, также с блоками конформера, принимает контекстные векторы и создает окончательные контекстуализированные речевые представления. Этот модуль предсказывает идентификаторы токенов на маскированных позициях с использованием слоя softmax

После предварительного обучения, при наличии доступа к помеченным данным, w2v-BERT может быть донастроен на две задачи: распознавание речи

(LibriSpeech) и голосовой поиск. w2v-BERT используется в сочетании с преобразователем последовательности и декодером LSTM для обработки помеченных данных, вставляя дополнительный проекционный слой между предварительно обученной моделью w2v-BERT и LSTM-декодером.

Значительной частью архитектуры w2v-BERT является использование различных блоков конформера, механизмов квантования и обучения на неразмеченных данных с целью создания идентификации речевых токенов и контекстуализированных представлений.

Conv + Transformer + wav2vec2.0 + pseudo labeling

Conv + Transformer + wav2vec2.0 + pseudo labeling [6] основан на совмещении двух методов обучения на неразмеченных данных - самообучения и безнадзорного предварительного обучения. Основной задачей являлось рассмотрение эффективности комбинирования этих двух методов.

Модель безнадзорного предварительного обучения (wav2vec 2.0): рассматривалась модель, содержащая сверточный кодировщик для преобразования аудио в скрытые речевые представления, а также трансформер для получения контекстных представлений. Модель обучалась путем решения контрастной задачи над скрытыми выводами кодировщика признаков и маскированием отрезков времени.

Метод самообучения: применялась стратегия псевдо-маркировки для обучения акустической модели на неразмеченных данных, где данные без меток маркировались начальной моделью и языковой моделью. Исследовались различные подходы к этому методу, включая многократное использование псевдо-маркировки и фильтрацию данных.

Комбинирование двух методов: проводились эксперименты по замене начальной модели для псевдо-маркировки на предварительно обученную модель. Таким образом, модель wav2vec 2.0 предварительно обучалась на

неразмеченных данных, после чего использовалась для маркировки неразмеченных данных и обучения конечной модели на этих данных.

Сравнительный анализ методов распознавания речи

Для проведения сравнительного анализа методов распознавания речи были рассмотрены перечисленные выше методы, заранее обученные модели и результаты их тестирования на общедоступном наборе данных LibriSpeech.

Модель SpeechStew применяла архитектуры с согласованными параметрами объемом 100M и 1B. В этом исследовании использовались экспериментальные настройки по умолчанию для обучения этих моделей.

Основные параметры модели "Conformer L" (100) включало оптимизацию Adam, где график скорости обучения трансформатора содержал 10-тысячные шаги разминки и пиковую скорость обучения в $2e-3$. Также был применен остаточный отсев и L2-регуляризация. Для увеличения входной спектрограммы было использовано адаптивное увеличение спецификации с двумя частотными масками и десятью временными масками.

Для модели с объемом параметров 1B, известной как "Conformer XXL", предварительное обучение модели wav2vec оказалось критически важным. Контрастные потери wav2vec были оптимизированы с использованием метода Adafactor. Для предварительного обучения модели Transformer применялся график темпов обучения. Оптимизация кодировщика и декодера проводилась отдельно с применением двух оптимизаторов Adafactor и двух графиков скорости обучения для трансформаторов.

В методе Noisy Student Training использовался набор данных LibriSpeech в качестве контрольного обучающего набора, а "unlab-60k" использовался в качестве немаркированного набора данных. Контрольные транскрипты использовались с помощью модели Word Piece Model (WPM). 80-мерные коэффициенты банка фильтров речи использовались в качестве входных признаков. Для обучения применялось семейство моделей ContextNets.

Было обучено пять поколений моделей. Базовая модель ContextNet имела тот же кодер, что и CN-1.25, но обладала однослойным декодером RNN с размерностью 640. ASR-модель с номерами от 1 до 4 представлена моделями CN-w с параметрами $w=1,25, 1,75, 2,25$ и $2,5$.

Каждое поколение было обучено на 128 чипах Google Cloud TPU. Выбор контрольной точки модели, используемой для слияния LM, осуществлялся на основе заданного WER. Настройки NST включали SpecAugment с адаптивным размером временной маски. Языковая модель (LM) - трехслойная LSTM-модель, обученная на корпусе LibriSpeech LM.

Фильтрация не применялась, а балансировка осуществлялась с параметрами. Было применено пакетное перемешивание с увеличением доли полуконтролируемых высказываний по поколениям.

В методе Conformer эксперименты проводились на трех моделях с различными объемами параметров. Исследовались разные комбинации глубины сети, размеров модели и числа голов внимания. Все модели включали однослойный декодер LSTM с применением отсева, вариационного шума и L2-регуляризации для стабилизации. Модели обучались с оптимизатором Adam и расписанием обучения трансформера на 10 000 этапов разогрева.

Использована Языковая модель (LM) с 3 слоями LSTM и шириной 4096. Параметры моделей настраивались на наборе для разработки.

Для обучения ContextNet использовался оптимизатор Adam с расписанием обучения, L2-регуляризация и декодер в виде однослойной LSTM с размерностью входа 640.

Для регуляризации был введен вариационный шум в декодер. Был применен SpecAugment с параметрами маски ($F = 27$) и десятью временными масками. Трехслойная LSTM-модель языковой модели (LM) с шириной 4096 обучалась на корпусе языковой модели LibriSpeech с добавлением транскрипций LibriSpeech960h, токенизированных с использованием 1k WPM. Использовались инструменты Lingvo для реализации моделей.

Предлагаемый метод W2V-BERT включал предварительное обучение и тонкую настройку следующим образом:

Предварительное обучение:

1. Использование только неразмеченные речевые данные.
2. Применение потери контраста и потери маскированного прогнозирования для обучения контрастного модуля и модуля маскированного прогнозирования.
3. Создание потерей контраста адекватных контекстных векторов и дискриминирующих дискретизированных речевых токенов.
4. Создание потерей маскированного прогнозирования окончательных контекстных векторов для задачи маскированного прогнозирования.
5. Одновременное решение обеих потерь как общей обучающей потерей.

Тонкая настройка:

1. Выполнение процесса на размеченных данных.
2. Применение предварительно обученной модели w2v-BERT к задачам LibriSpeech и поиску по голосу.
3. Использование предварительной обученной модели w2v-BERT вместе с декодером LSTM для обучения всей системы на размеченных данных.
4. Финетюнинг весов модели w2v-BERT в соответствии с требованиями конкретных задач.

Ключевая идея заключалась в том, что совместное обучение контрастного модуля и модуля маскированного прогнозирования в процессе предварительного обучения позволяло извлекать контекстуализированные речевые представления из неразмеченных данных. Затем, тонкая настройка применялась к предварительно обученной модели для выполнения конкретных задач, таких как распознавание речи и поиск по голосу.

В методе использовались неразмеченные данные из набора Libri-Light unlab-60k для предварительного обучения, а размеченные данные использовались для оценки производительности моделей (часть LibriSpeech 960 часов).

В рамках исследования Conv + Transformer + wav2vec2.0 + pseudo labeling использовался подход, объединяющий сверточные слои, трансформер и предварительно обученную модель wav2vec 2.0 для обучения акустических моделей на данных Librispeech (LS-960), включая как размеченные, так и неразмеченные аудиоданные. Варьировались варианты размеченных данных от полного набора до ограниченных по ресурсам тренировочных наборов, и оценка производилась на стандартных наборах данных Librispeech.

Предварительно обученные модели, полученные из репозитория fairseq на GitHub, базировались на различных конфигурациях размеченных данных, с основной моделью LARGE, содержащей различные блоки трансформера, временные свертки и пространство приема. Эти модели предварительно обучались на неразмеченных данных

В методе самообучения использовалась стратегия псевдо-маркировки на LS-960 с применением wav2vec 2.0 LARGE. Маркировка осуществлялась с использованием двухпроходного переоценивания CTC и трансформерной языковой модели, что приводило к более эффективным результатам по сравнению с интеграцией языковой модели в поиск с лучом.

Окончательная модель обучалась на последовательностях логарифмического спектра мел-фильтрбанка после этапа псевдо-маркировки, используя wav2letter++. Модель включала передний конволюционный слой и блоки трансформера, а словарь из 10000 слов настраивался на тренировочных данных в зависимости от использования всей обучающей выборки или только размеченных данных. Такой подход позволял исследователям оценить производительность различных моделей с учетом использования неразмеченных данных и различных объемов размеченных данных в процессе обучения.

Результаты исследования. Сводная таблица

Таблица представляет собой значения WER.

Частота ошибок в словах (WER) – это метрика, используемая в задачах распознавания речи для измерения ошибок в распознанных словах по сравнению с фактическими словами.

Качество распознавания по метрике WER измеряется по формуле:

$$WER = 100 * (S + I + D) / N$$

S – означает замены,

I – означает вставки,

D – обозначает удаление,

N – количество слов в ссылке (которые были фактически сказаны).

Исследования проводились для двух типов данных: "clean" (чистые) и "other" (другие) в рамках набора данных LibriSpeech, учитывая наличие или отсутствие использования языковой модели (LM).

Разница между наборами данных "clean" и "other" заключается в уровне качества записи и условиях: "clean" содержит чистые аудиоданные с минимальным шумом и является контролируемым набором для оценки в идеальных условиях, в то время как "other" представляет собой более разнообразные данные с различными видами шума и условиями, предназначенные для оценки в более реалистичных и менее контролируемых условиях.

Набор данных LibriSpeech включает различные аудиозаписи аудиокниг, охватывающих широкий спектр разговорной речи.

В описанных методах и экспериментах модели были обучены, используя 960 часов размеченной речи из LibriSpeech. Эти данные предоставляют моделям достаточное количество примеров для обучения и оценки их производительности в задаче распознавания речи.

Таблица 1: Значения WER (%) при использовании подмножества LibriSpeech 960hr в качестве контролируемых данных.

Методы	LibriSpeech			
	NO LM		LM	
	clean	other	clean	other
SpeechStew (L)	2,0	4,0		
SpeechStew (XXL)	1,7	3,3		
Conformer(M)	2,3	5,0	2,0	4,3
Conformer(L)	2,1	4,3	1,9	3,9
ContextNet(M)	2,4	5,4	2	4,5
ContextNet(L)	2,1	4,6	1,9	4,1
ContextNet + NST	1,7	3,7	1,7	3,4
Wav2vec XXL	1,4	2,5	1,4	2,5

По результатам таблицы можно сделать следующие выводы:

SpeechStew предлагает обучение универсальной модели, которую можно точно настроить для конкретных задач. Однако результаты этой модели, особенно на наборе LibriSpeech, часто уступают моделям, таким как Conformer + Wav2vec 2.0 с использованием Noisy Student Training с немаркированными данными Libri-Light.

Conformer, с использованием сверточных слоев и архитектуры Transformer, демонстрирует превосходство над LSTM и другими моделями на тестовых наборах данных LibriSpeech. Кроме того, дополнительное использование языковой модели позволяет снизить ошибки слов, что подтверждает эффективность архитектуры Transformer и сверточных слоев.

ContextNet в свою очередь привносит значительное улучшение по сравнению с предыдущими системами, что особенно заметно на более крупных моделях. Это связано с тем, что даже модель с меньшим количеством параметров (ContextNet(M)) достигает конкурентоспособных результатов.

Wav2vec 2.0 отличается от других методов своей способностью обучать модуль дискретизации речи и основной модуль контекстуализированных представлений одновременно. Это позволяет моделям эффективно моделировать речь и приносит преимущество по сравнению с другими методами, включая трансформеры.

Псевдо-маркировка (pseudo labeling) становится популярной стратегией обучения на неразмеченных данных. Предварительно обученные модели, такие как wav2vec 2.0, могут быть донастроены на неразмеченных данных с использованием различных подходов. Наиболее успешными оказываются модели, использующие CTC (Connectionist Temporal Classification) для донастройки на псевдо-маркированных данных.

Из таблицы видно, что метод Wav2Vec XXL демонстрирует наилучшие результаты с самым низким WER.

Сравнение результатов различных методов обучения на наборе данных LibriSpeech показывает, что выбор оптимальной стратегии может зависеть от особенностей конкретной задачи. Например, в некоторых случаях, модели, обученные на псевдо-маркированных данных, показывают лучшие результаты без использования языковой модели, в то время как другие модели с языковой моделью в процессе псевдо-маркировки демонстрируют высокую производительность даже без использования языковой модели во время вывода. Или метод NST может быть эффективным при недостатке размеченных данных, в то время как Conformer может обеспечить высокую точность в распознавании речи.

Заключение.

Исследования, представленные в рассмотренных четырех разделах текста, подчеркивают важность обучения на неразмеченных данных для улучшения автоматического распознавания речи (ASR). Разнообразные методы и модели, такие как "wav2vec 2.0", "Conformer", "ContextNet", и стратегии самообучения,

включая псевдо-маркировку, показывают потенциал для значительного повышения производительности систем ASR.

Комбинирование различных методов и подходов также демонстрирует обещающие результаты, особенно при использовании предварительно обученных моделей для обучения на неразмеченных данных. Эти исследования проливают свет на возможности применения современных методов глубокого обучения и нейронных сетей для развития более точных и эффективных систем распознавания речи.

В целом, применение неразмеченных данных и разработка новых стратегий обучения открывают перспективы для улучшения ASR и позволяют создавать более надежные и точные системы распознавания речи для широкого спектра практических задач.

В заключение, важно отметить, что выбор оптимальной стратегии обучения на неразмеченных данных может зависеть от особенностей конкретных задач и доступных данных. Различные модели и методы могут демонстрировать превосходство в разных сценариях.

Литература

- [1] «SpeechStew: Simply Mix All Available Speech Recognition Data to Train One Large Neural Network» William Chan, Daniel Park, Chris Lee, Yu Zhang, Quoc Le, Mohammad Norouzi
- [2] “Improved Noisy Student Training for Automatic Speech Recognition” D. S. Park, Y. Zhang, Y. Jia, W. Han, C.-C. Chiu, B. Li, Y. Wu, and Q. V. Le
- [3] «Conformer: Convolution-augmented Transformer for Speech Recognition» Anmol Gulati, James Qin, Chung-Cheng Chiu, Niki Parmar, Yu Zhang, Jiahui Yu, Wei Han, Shibo Wang, Zhengdong Zhang, Yonghui Wu, Ruoming Pang
- [4] «ContextNet: Improving Convolutional Neural Networks for Automatic Speech Recognition with Global Context» Wei Han, Zhengdong Zhang, Yu Zhang, Jiahui Yu, Chung-Cheng Chiu, James Qin, Anmol Gulati, Ruoming Pang, Yonghui Wu
- [5] «W2v-BERT: Combining Contrastive Learning and Masked Language Modeling for Self-Supervised Speech Pre-Training» Yu-An Chung, Yu Zhang, Wei Han, Chung-Cheng Chiu, James Qin, Ruoming Pang, Yonghui Wu
- [6] «Self-training and Pre-training are Complementary for Speech Recognition» Qiantong Xu, Alexei Baevski, Tatiana Likhomanenko, Paden Tomasello, Alexis Conneau, Ronan Collobert, Gabriel Synnaeve, Michael Auli
- [7] V. Panayotov, G. Chen, D. Povey, and S. Khudanpur, “Librispeech: An ASR corpus based on public domain audio books,” in ICASSP, 2015
- [8] A. Gulati, J. Qin, C.-C. Chiu, N. Parmar, Y. Zhang, J. Yu, W. Han, S. Wang, Z. Zhang, Y. Wu, and R. Pang, “Conformer: Convolution-augmented Transformer for Speech Recognition,” in INTERSPEECH, 2020.
- [9] A. Graves, “Sequence Transduction with Recurrent Neural Networks,” in ICML Representation Learning Workshop, 2012.

Research of teaching methods for Automatic Speech Recognition (ASR)

Annotation

This article discusses modern training methods for automatic speech recognition (ASR). Six methods are reviewed: SpeechStew, Noisy Student Training, Conformer, ContextNet, W2V-BERT and Conv + Transformer + wav2vec2.0 + pseudo labeling.

Keywords

automatic speech recognition (ASR)

learning methods

untagged data

transformers

self-learning

unsupervised pre-training